

Отчёт: SFT и GRPO для навигационного агента в среде MiniGrid

Глухих Егор

Июнь 2026

1 Итоговое резюме

Реализован пайплайн обучения vision-language модели (nanoVLM-222M) для задачи навигации в MiniGrid-Empty. Сравниваются три режима:

1. **SFT** — имитационное обучение на экспертных траекториях (greedy shortest-path);
2. **GRPO-action** — групповая оптимизация политики, модель выдаёт только действие;
3. **GRPO-текст + действие** — GRPO с генерацией цепочки рассуждений перед действием.

Ключевой результат: SFT в одиночку не обобщается на 16×16 (success $\approx 0\%$), однако GRPO с curriculum ($8 \rightarrow 10 \rightarrow 12 \rightarrow 16$) поверх SFT достигает 100% success rate на 16×16 за 20 итераций.

2 Данные, эксперт и формат ввода/вывода

Среда: MiniGrid-Empty- $N \times N$ -v0 ($N \in \{6, 8, 10, 12, 16\}$). Агент видит RGB-изображение полного грида (вид сверху), должен дойти до зелёной клетки.

Эксперт: greedy shortest-path — оптимален для пустого грида, 200 эпизодов для SFT.

Формат ввода:

<image> Question: You are a navigation agent in a grid world.
Choose the next action: 0=left, 1=right, 2=forward. Answer:

Формат вывода для grpo: один токен из $\{0, 1, 2\}$.

Формат вывода для модели текст + действие):

Thought: I am facing east, goal is ahead. I should move forward.

Action: 2

3 Графики обучения




Рис. 1: график обучения SFT




Рис. 2: График обучения GRPO curriculum




Рис. 3: График обучения GRPO-текст + действие

4 Сводная таблица результатов

5 Сравнение по sample efficiency и финальному качеству

- **SFT** — быстро учится на in-distribution (3 эпохи, ~ 200 эпизодов), но не обобщается: на 16x16 success $\approx 0\%$.
- **GRPO без curriculum** — на 6x6 reward быстро насыщается (уже 100% после 4 итер), но навык не переносится на 16x16 — модель не видела длинных горизонтов.
- **GRPO curriculum** — 20 итераций (4 стадии по 5), каждая стадия ~ 5 мин. На стадии 4 (16x16) модель резко переходит от 0% к 100% — curriculum обеспечивает плавный градиентный сигнал.

6 Выводы

Что работало

- Curriculum learning — критичен для обобщения; без него ни SFT, ни GRPO не решают 16x16.
- Инициализация GRPO из SFT — без неё reward signal на больших средах отсутствует (модель не финиширует ни разу поэтому нулевой градиент).
- Step penalty в reward помогает формировать кратчайшие пути.

Что не работало

- GRPO напрямую на 16x16 — нулевой reward, нет сигнала для обновления.
- SFT curriculum без GRPO: модель запоминает паттерны, но не обобщает (100% на 8x8, 0% на 16x16).
- Но при этом на стадии GRPO curriculum 8x8 success упал до 0%, то есть модель начала забывать при переходе к следующим стадиям

7 Дальнейшие улучшения

Метод	Env	Success Rate	Avg Return
SFT baseline	6x6	100%	0.873
SFT baseline	16x16	6%	0.056
GRPO-action (no curriculum)	6x6	100%	0.934
GRPO-action (no curriculum)	16x16	0%	0.000
SFT curriculum	8x8	100%	0.961
SFT curriculum	16x16	0%	0.000
GRPO-action curriculum	10x10	100%	0.966
GRPO-action curriculum	16x16	100%	0.976
GRPO-text+action	16x16	<i>100%</i>	<i>0.969</i>

Таблица 1: Сравнение методов. GRPO curriculum — единственный, решивший 16x16.